

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA KHOA HỌC MÁY TÍNH



SELF-STUDY

Đề tài: BERT

Mentor: My self

Student: Lại Khánh Hoàng

Tp. Hồ Chí Minh



Mục lục

1	BERT Structure	2
1.1	Masked language modelling	2
1.2	Sentence matching / Next sentence prediction	2
2	Fine-tune BERT	2



1 BERT Structure


BERT là mô hình ngôn ngữ được train để tạo word embedding, nó bỏ qua phần transformer decoder. Vector embed này giàu thông tin, hiểu ngữ cảnh hai chiều. Sau khi pre-train, chúng ta có thể fine-tune model trên task thực sự.

BERT được pre-train trên dữ liệu text lớn với hai nhiệm vụ chính:

- Masked Language Modelling
- Sentence Matching/Next Sentence Prediction

Sau khi pre-train trên dữ liệu cực lớn, chúng ta sẽ fine-tune nó tác vụ phía sau.

Tại sao BERT hiểu ngữ cảnh hai chiều ? Nhớ rằng cơ chế self-attention trong transformers hiểu được mối quan hệ giữa các từ trong cùng 1 câu. Tính chất này giúp nó hiểu ngữ cảnh của 1 từ dựa trên các từ bên cạnh.



1.1 Masked language modelling

Trước khi đưa câu vào BERT, 15% số từ trong mỗi câu được thay thế bằng một token [MASK]. Model cố gắng dự đoán từ bị che dựa trên ngữ cảnh được cung cấp bởi các từ không bị che trong câu.

1.2 Sentence matching / Next sentence prediction

Mô hình nhận một cặp câu làm đầu vào và học cách dự đoán xem câu thứ hai trong cặp đó có phải là câu tiếp theo của câu thứ nhất hay không.

2 Fine-tune BERT

- Các tác vụ phân loại như Sentiment Analysis được làm tương tự như bài toán Next sentence prediction, bằng việc thêm một lớp phân loại vào output của Transformer cho token [CLS]
- QA Tasks: Mô hình nhận vào một câu hỏi liên quan đến một chuỗi văn bản, và nhiệm vụ của nó là xác định (đánh dấu) phần câu trả lời nằm trong chuỗi đó. Khi sử dụng BERT, mô hình Hỏi – Đáp (QA) có thể được huấn luyện bằng cách học thêm hai vector, để xác định vị trí bắt đầu và vị trí kết thúc của câu trả lời trong đoạn văn.

Ví dụ: Mô hình **SQuAD v1.1** nhận vào một đoạn văn bản (context) và một câu hỏi (question) liên quan đến đoạn văn đó, sau đó mô hình phải tìm ra câu trả lời, bằng cách đánh dấu vị trí bắt đầu (start) và vị trí kết thúc (end) của câu trả lời trong đoạn context. Cụ thể:

- Input được đưa vào BERT như sau: "[CLS] Question [SEP] Context [SEP]"

Mô hình sẽ encode toàn bộ chuỗi này vì BERT đã hiểu ngữ nghĩa rất tốt nhờ pretrain (masked language + next sentence prediction), xuất ra một vectơ ẩn: $[h_0, \dots, h_n], h_i \in \mathbb{R}^{768}$

- Khi fine-tune cho question answering, ta thêm hai vector học được mới:

$$P_{start}(i) = \text{softmax}(w_{start}^T h_i), P_{end}(i) = \text{softmax}(w_{end}^T h_i); w_{start}, w_{end} \in \mathbb{R}^{768}$$